

LAPORAN TEKNIS DATA SCIENCE

Coding Camp 2026 powered by DBS Foundation

Karisma AI: AI Career Navigator & Skill Intelligence untuk Mahasiswa

Keterangan	Detail
ID Tim	CC26-PSU202
Tema Capstone	Future-Ready Work & Economy
Fokus Laporan	Data Science
Data Scientist	Alfi Syahrin & Mayadi Alamsyah Putra Silalahi
Periode Scraping	02 Mei 2026 – 10 Mei 2026
Tanggal Laporan	30 Mei 2026

BAB I — PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi digital dan transformasi industri yang pesat telah mengubah kebutuhan keterampilan di pasar kerja secara signifikan. Laporan dari McKinsey Global Institute dan World Economic Forum menunjukkan bahwa banyak pekerjaan mengalami perubahan kebutuhan skill, sehingga individu dituntut untuk terus beradaptasi dan mengembangkan kompetensi yang relevan.

Di Indonesia, tantangan ini diperkuat oleh terbatasnya layanan career guidance berbasis data di perguruan tinggi. Mahasiswa cenderung mengandalkan informasi umum atau mengikuti tren tanpa memahami kecocokan antara kemampuan yang dimiliki dengan kebutuhan industri yang terus berkembang. Platform career planning yang tersedia saat ini pada umumnya hanya berfokus pada pembuatan CV atau pencarian lowongan kerja, tanpa menyediakan analisis mendalam mengenai kecocokan skill dengan bidang karir tertentu.

Akibatnya, banyak lulusan mengalami mismatch antara kompetensi yang dimiliki dengan kebutuhan industri, yang pada akhirnya berdampak pada rendahnya kesiapan kerja dan produktivitas tenaga kerja Indonesia. Kondisi ini menjadi dasar pengembangan Karisma AI sebagai platform career intelligence berbasis data yang tidak hanya memberikan rekomendasi karir, tetapi juga membantu mahasiswa memahami profil skill mereka secara akurat.

Dalam ekosistem proyek Karisma AI, peran Data Science mencakup seluruh pipeline pengolahan data: mulai dari pengumpulan data lowongan kerja melalui web scraping, pembersihan dan transformasi data, analisis eksploratif mendalam, hingga penyajian insight melalui dashboard interaktif dan penyediaan data terstruktur untuk kebutuhan model AI dan aplikasi web.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah yang menjadi fokus pada laporan ini adalah:

1. Bagaimana kondisi pasar kerja digital Indonesia saat ini ditinjau dari distribusi industri, jenis pekerjaan, pengaturan kerja, dan tingkat pendidikan yang dibutuhkan?

2. Skill apa saja yang paling banyak diminati oleh industri, dan skill apa yang memiliki korelasi tertinggi terhadap tingkat kompensasi?
3. Bagaimana hubungan antara tingkat pengalaman kerja yang dibutuhkan dengan rentang kompensasi yang ditawarkan di berbagai kategori pekerjaan?
4. Kategori pekerjaan apa yang menawarkan kompensasi tertinggi, dan bagaimana distribusi salary tier di seluruh dataset?
5. Bagaimana pipeline data yang efektif dapat dibangun untuk mendukung kebutuhan model AI (NLP) dan database production Karisma AI?

1.3 Tujuan

Tujuan dari laporan teknis ini adalah:

- Mendokumentasikan secara komprehensif seluruh proses pipeline data science yang telah dibangun dalam proyek Karisma AI.
- Menyajikan temuan analitik dari eksplorasi data pasar kerja Indonesia yang diperoleh dari platform Glints.
- Menjelaskan keputusan teknis dan metodologi yang digunakan dalam setiap tahap pipeline, mulai dari scraping hingga seeding database.
- Menyediakan dasar data yang terverifikasi untuk mendukung pengembangan model NLP dan sistem rekomendasi karir oleh tim AI Engineer.

1.4 Ruang Lingkup

Laporan ini secara khusus membahas kontribusi peran Data Science dalam proyek Karisma AI, yang meliputi:


- Web scraping data lowongan kerja dari platform Glints Indonesia.
- Data cleaning, wrangling, dan feature engineering dataset job market.
- Exploratory Data Analysis (EDA) mendalam untuk menjawab research questions bisnis.
- Pembangunan dan deployment Streamlit EDA Dashboard untuk publik.

- Penyiapan file output terstruktur untuk kebutuhan tim AI Engineer dan database seeding.

BAB II — METODOLOGI DAN ARSITEKTUR PIPELINE

2.1 Gambaran Umum Pipeline Data Science

Pipeline data science yang dibangun dalam proyek Karisma AI terdiri dari empat tahap utama yang saling berkesinambungan. Setiap tahap menghasilkan output yang menjadi input bagi tahap berikutnya, membentuk alur kerja yang kohesif dari sumber data mentah hingga data siap pakai untuk production.



Gambar 2.1 — Arsitektur Pipeline Data Science Karisma AI

Secara ringkas, alur pipeline tersebut adalah sebagai berikut:

1. Glints Scraper → menghasilkan full_dataset_glints.csv (±60.000 baris data mentah)
2. Notebook Analisis → menghasilkan tiga file output: (a) glints_nlp_ready.csv untuk model NLP, (b) glints_v2_cleaned.csv untuk dashboard, (c) glints_category_output.csv untuk database seeding
3. Streamlit Dashboard → dikembangkan dari glints_v2_cleaned.csv, di-deploy ke Streamlit Cloud
4. Database Seeder → membaca glints_category_output.csv dan mengisi tabel di Supabase (PostgreSQL)

2.2 Teknologi dan Tools

Berikut adalah teknologi yang digunakan dalam pipeline Data Science proyek Karisma AI:

Teknologi / Library	Versi	Fungsi
Python	3.10+	Bahasa pemrograman utama
Pandas	2.x	Manipulasi dan pembersihan data tabular
NumPy	1.x	Operasi numerik dan array
Requests	2.x	HTTP client untuk scraping API
Matplotlib	3.x	Visualisasi dasar (line, bar, scatter)
Seaborn	0.x	Visualisasi statistik (heatmap, boxplot)
Plotly	5.x	Visualisasi interaktif untuk Streamlit
Scikit-learn	1.x	MinMaxScaler untuk normalisasi salary
Streamlit	1.x	Framework dashboard EDA interaktif
Psycopg2	2.x	Koneksi ke database PostgreSQL/Supabase
Jupyter Lab	-	Environment pengembangan notebook

Tabel 2.1 — Teknologi yang Digunakan dalam Pipeline Data Science

2.3 Sumber Data

Data yang digunakan dalam proyek Karisma AI bersumber sepenuhnya dari hasil web scraping platform Glints Indonesia (glints.com/id). Glints merupakan salah satu platform rekrutmen terbesar di Asia Tenggara yang memiliki cakupan luas terhadap lowongan pekerjaan dari berbagai industri dan fungsi pekerjaan di Indonesia.

Pemilihan Glints sebagai sumber data utama didasarkan pada beberapa pertimbangan:

- Ketersediaan data yang kaya: setiap posting lowongan memuat informasi skill yang dibutuhkan, kategori pekerjaan, industri, pengaturan kerja, pendidikan, pengalaman, dan informasi salary.
- Relevansi terhadap pasar kerja Indonesia: Glints secara aktif digunakan oleh perusahaan-perusahaan lokal maupun multinasional yang beroperasi di Indonesia.
- Aksesibilitas melalui API: Glints menyediakan endpoint GraphQL yang dapat diakses untuk mengambil data lowongan secara terstruktur.

- Cakupan kategori yang luas: mencakup industri teknologi, keuangan, pendidikan, ritel, manufaktur, dan berbagai sektor lainnya.

Perlu dicatat bahwa data yang dikumpulkan merupakan data publik yang tersedia di platform Glints dan digunakan semata-mata untuk keperluan riset dan pengembangan sistem rekomendasi karir non-komersial dalam konteks proyek capstone akademis.

BAB III — PENGUMPULAN DATA (WEB SCRAPING)

3.1 Strategi Scraping

Pengumpulan data dilakukan menggunakan script Python (`glints_scrapper.py`) yang memanfaatkan endpoint GraphQL Glints pada URL `https://glints.com/api/v2-alc/graphql?op=searchJobsV3`. Pendekatan GraphQL dipilih karena memungkinkan pengambilan data yang terstruktur dengan field yang dapat ditentukan secara eksplisit, sehingga mengurangi overhead data yang tidak diperlukan.

Untuk memaksimalkan cakupan data, scraping dilakukan dengan kombinasi filter multi-dimensi yang mencakup seluruh kombinasi dari empat parameter utama:

Parameter Filter	Nilai yang Digunakan	Jumlah Nilai
Job Type	FULL_TIME, CONTRACT, INTERNSHIP, PART_TIME, FREELANCE, PROJECT_BASED	6
Work Arrangement	ONSITE, HYBRID, REMOTE	3
Experience Level	NO_EXPERIENCE, FRESH_GRAD, LESS_THAN_A_YEAR, ONE_TO_THREE_YEARS, THREE_TO_FIVE_YEARS, FIVE_TO_TEN_YEARS, MORE_THAN_TEN_YEARS	7
Education Level	PRIMARY_SCHOOL, SECONDARY_SCHOOL, HIGH_SCHOOL, DIPLOMA, BACHELOR_DEGREE, PROFESSIONAL_EDUCATION, MASTER_DEGREE, DOCTORATE	8
Total Kombinasi	$6 \times 3 \times 7 \times 8$	1.008

Tabel 3.1 — Parameter Filter Kombinasi Scraping

Pendekatan kombinasi filter ini dipilih untuk mengatasi keterbatasan pagination API Glints yang membatasi maksimal offset halaman per query. Dengan memecah permintaan menjadi 1.008 kombinasi filter yang lebih spesifik, setiap bucket query menghasilkan jumlah posting yang lebih sedikit dan lebih mudah dipaginasi hingga tuntas, sehingga secara keseluruhan cakupan data menjadi lebih komprehensif.

3.2 Mekanisme Pengambilan Data

Setiap kombinasi filter dikirimkan sebagai payload GraphQL ke endpoint Glints dengan parameter tambahan: `CountryCode = ID` (Indonesia), `sortBy = LATEST`, `lastUpdatedAtRange = ANY_TIME`, dan `pageSize = 30` (30 posting per halaman). Proses pagination dilakukan secara iteratif selama field `hasMore` bernilai `True` pada response.

Setiap posting yang berhasil dikumpulkan diekstraksi untuk memperoleh field-field berikut:

Field Raw	Keterangan
<code>id</code>	ID unik posting untuk membentuk URL lowongan
<code>title</code>	Nama jabatan/posisi pekerjaan
<code>company.industry.name</code>	Nama industri perusahaan
<code>hierarchicalJobCategory</code>	Nama dan level kategori pekerjaan (hingga 3 level hierarki)
<code>salaries</code>	Mode pembayaran, batas bawah, dan batas atas gaji
<code>skills</code>	Daftar skill yang dibutuhkan
<code>workArrangementOption</code>	Pengaturan lokasi kerja
<code>type</code>	Tipe kontrak pekerjaan
<code>educationLevel</code>	Tingkat pendidikan minimum
<code>minYearsOfExperience</code>	Minimum tahun pengalaman kerja

Tabel 3.2 — Field yang Diekstraksi dari API Glints

3.3 Mekanisme Fault Tolerance

Untuk menjaga stabilitas proses scraping yang berjalan dalam jangka panjang, script dilengkapi dengan beberapa mekanisme proteksi:

- Rate limiting adaptif: jeda acak antara 1,5 hingga 3,5 detik antar halaman untuk menghindari deteksi bot.
- Retry mechanism: setiap request dilakukan maksimal 3 kali percobaan sebelum dinyatakan gagal dan dilompati.

- Handling status code: penanganan khusus untuk status 400 (batas offset), 401/403 (sesi kedaluwarsa), dan 429 (too many requests dengan jeda 30 detik).
- Resume capability: progres disimpan dalam file progress_glints.txt berisi daftar filter yang sudah selesai, sehingga proses dapat dilanjutkan dari titik terakhir jika terjadi interupsi.
- Incremental write: setiap posting langsung di-flush ke file CSV setelah setiap halaman berhasil diambil, menghindari kehilangan data jika terjadi crash.

3.4 Hasil Pengumpulan Data

Proses scraping dilaksanakan pada Mei 2026. Berikut adalah ringkasan statistik hasil pengumpulan data:

Metrik	Nilai
Total kombinasi filter yang diproses	1008 dari 1.008
Total baris data mentah terkumpul	±70000 baris
Total unique industri	138 Industri
Total unique job_category	619 Data
Total unique skill (raw, sebelum cleaning)	41805 Skills List

Tabel 3.3 — Statistik Hasil Pengumpulan Data

```

PS C:\code\Scrapping_glints> python -u "c:\code\Scrapping_glints\main_scrapper_v4 copy.py"
=== MEMULAI FULL SCRAPING (RESUME CAPABLE & FAST MODE) ===

=====
[*] FILTER AKTIF: FULL_TIME | ONSITE | FRESH_GRAD | PRIMARY_SCHOOL
=====

-> Mengambil halaman 1...
    [zZz] Sukses. Jeda 2.57 detik...
-> Mengambil halaman 2...
    [zZz] Sukses. Jeda 2.96 detik...
-> Mengambil halaman 3...
    [zZz] Sukses. Jeda 2.78 detik...
-> Mengambil halaman 4...
    [zZz] Sukses. Jeda 2.73 detik...
-> Mengambil halaman 5...
    [zZz] Sukses. Jeda 1.57 detik...
-> Mengambil halaman 6...
    [zZz] Sukses. Jeda 2.92 detik...
-> Mengambil halaman 7...

```

Gambar 3.1 — Contoh Output Terminal Proses Scraping

BAB IV — DATA UNDERSTANDING DAN DATA CLEANING

4.1 Struktur Dataset Mentah

Dataset mentah hasil scraping (`full_dataset_glints.csv`) memiliki 13 kolom dan ± 70000 baris. Setiap baris merepresentasikan satu posting lowongan kerja. Berikut adalah deskripsi lengkap struktur dataset mentah:

Kolom	Tipe Data Raw	Deskripsi
Job_Link	string	URL unik lowongan (format: <code>glints.com/id/opportunities/jobs/<id></code>)
Title	string	Nama jabatan pekerjaan
Industry	string	Nama industri perusahaan
Job_Category_parent	string	Fungsi pekerjaan utama (Level 2 hierarki)
Job_Category	string	Spesialisasi pekerjaan detail (Level 3)
Salary_Mode	string	Satuan pembayaran gaji (MONTH/YEAR/HOUR/dll)
Min_Salary	float	Batas bawah gaji dalam satuan Salary_Mode (IDR)
Max_Salary	float	Batas atas gaji dalam satuan Salary_Mode (IDR)
Skills	string	Daftar skill dipisah koma (raw, belum dinormalisasi)
Job_Type	string	Tipe kontrak (FULL_TIME/CONTRACT/dll)
Work Arrangement	string	Pengaturan lokasi kerja (ONSITE/HYBRID/REMOTE)
Education	string	Tingkat pendidikan minimum (enum)
Experience	integer	Minimum tahun pengalaman kerja

Tabel 4.1 — Struktur Dataset Mentah `full_dataset_glints.csv`

4.2 Data Quality Assessment

Sebelum melakukan cleaning, dilakukan asesmen kualitas data secara menyeluruh untuk mengidentifikasi masalah yang perlu ditangani. Asesmen mencakup pemeriksaan missing values, duplikasi data, outlier, dan konsistensi nilai kategorikal.

4.2.1 Missing Values

Analisis missing values pada dataset mentah menunjukkan pola sebagai berikut:

Kolom	Jumlah Missing	Persentase (%)	Keterangan
Industry	1158	1.58%	Diisi 'UNKNOWN' saat cleaning
Job_Category_parent	0	0%	Diisi berdasarkan Job_Category
Job_Category	0	0%	Diisi 'UNKNOWN'
Salary_Mode	10629	14.53%	Null = posting tanpa salary
Min_Salary	0	0%	Nilai 0 diperlakukan sebagai null
Max_Salary	2407	3.29%	Diisi dari Min_Salary jika null
Skills	0	0%	Diisi string kosong

Tabel 4.2 — Hasil Asesmen Missing Values

Missing Values Dataset		
	Jumlah Missing	Persentase (%)
Industry	1158	1.58
Job_Category_parent	0	0.00
Job_Category	0	0.00
Salary_Mode	10629	14.53
Min_Salary	0	0.00
Max_Salary	2407	3.29
Skills	0	0.00
Total baris dataset mentah (df_raw): 73,154		
Duplikat penuh (full row)	: 23,307	(31.86%)
Duplikat Job_Link saja	: 25,124	

Gambar 4.1 — Output Analisis Missing Values dari Notebook

4.2.2 Duplikasi Data

Duplikasi diperiksa berdasarkan kombinasi Job_Link (ID unik posting) dan konten. Berdasarkan data sebanyak 73514 baris data, terdapat 23307 data duplikat penuh dan 25124 data duplikat pada job link nya.

4.2.3 Distribusi Nilai Salary

Kolom Min_Salary dan Max_Salary memiliki karakteristik yang perlu mendapat perhatian khusus:

- Nilai 0 pada Min_Salary dan Max_Salary merepresentasikan posting tanpa informasi salary, bukan gaji nol yang sesungguhnya. Nilai ini diperlakukan sebagai null saat konversi.
- Terdapat outlier ekstrem di mana beberapa posting mencantumkan Max_Salary > 100 juta IDR per bulan, yang kemungkinan merupakan data tidak valid atau kesalahan input.
- Terdapat 30 data dengan Max_Salary > 100 juta IDR per bulan (0.04% dari total), Outlier ini dicap pada persentil ke 99.

4.3 Proses Data Cleaning

Berdasarkan hasil asesmen, proses cleaning dilakukan secara sistematis dengan urutan sebagai berikut:

4.3.1 Penanganan Missing Values dan Duplikat

1. Drop baris duplikat penuh menggunakan `df.drop_duplicates()`.
2. Mengisi missing value pada kolom Industry dengan string 'UNKNOWN'.
3. Mengisi missing value pada kolom Job_Category_parent dan Job_Category berdasarkan konteks data yang tersedia.
4. Mengisi missing value pada kolom Skills dengan string kosong.

4.3.2 Konversi dan Normalisasi Salary

Tantangan terbesar dalam cleaning adalah heterogenitas kolom Salary_Mode. Gaji yang tercatat dalam satuan berbeda (per jam, per hari, per minggu, per bulan, per tahun, per proyek) perlu dikonversi ke satu basis yang seragam: IDR per bulan. Konversi dilakukan menggunakan tabel multiplier sebagai berikut:

Salary_Mode	Multiplier ke Bulanan	Asumsi
MONTH	$\times 1$	Sudah dalam satuan bulanan
YEAR	$\div 12$	Dibagi 12 bulan
HOURL	$\times 173$	Rata-rata 173 jam kerja per bulan
DAY	$\times 22$	Rata-rata 22 hari kerja per bulan
WEEK	$\times 4.33$	Rata-rata 4,33 minggu per bulan
PROJECT	$\times 1$	Diasumsikan setara bulanan

Tabel 4.3 — Tabel Multiplier Konversi Salary ke Bulanan

Setelah konversi ke IDR per bulan, gaji kemudian dikonversi ke USD menggunakan kurs tetap yang ditetapkan di notebook (1 USD = Rp 17.000) untuk memudahkan perbandingan lintas kategori. Selain itu, dibuat beberapa representasi turunan:

- salary_min_monthly, salary_max_monthly: IDR per bulan
- salary_min_jt, salary_max_jt, salary_avg_jt: IDR per bulan dalam satuan Juta (untuk readability)
- salary_min_usd, salary_max_usd, salary_avg_usd: USD per bulan
- salary_avg_capped: salary_avg_usd yang di-clip di persentil ke-99 untuk menghilangkan outlier
- salary_normalized: MinMaxScaler [0,1] dari salary_avg_capped untuk input model NLP
- salary_tier dan salary_tier_encoded: klasifikasi bertingkat (Entry s/d Executive)

4.3.3 Normalisasi Skill

Kolom Skills dalam dataset mentah memiliki tingkat variasi nama yang sangat tinggi untuk merujuk pada skill yang sama. Contohnya, skill Microsoft Excel dapat muncul sebagai 'Ms Excel', 'MS Excel', 'excel', 'microsoft excel', 'Excel Spreadsheet', dan lain sebagainya. Kondisi ini jika dibiarkan akan menyebabkan fragmentasi data skill yang tidak mencerminkan popularitas skill yang sesungguhnya.

Untuk menangani masalah ini, dibangun sebuah kamus normalisasi (SKILL_CANONICAL) yang memetakan berbagai variasi penulisan ke satu nama standar yang telah ditentukan. Proses normalisasi mencakup:

1. Lowercase dan strip whitespace pada semua token skill.
2. Lookup di SKILL_CANONICAL dict — jika ditemukan, ganti dengan nama standar.
3. Jika tidak ada di dict, gunakan nilai original (sudah ter-lowercase dan ter-strip).

Hasil normalisasi menunjukkan pengurangan jumlah unique skill dari **8901** (sebelum normalisasi) menjadi **8218** (setelah normalisasi), menunjukkan efektivitas proses deduplikasi nama skill.

4.3.4 Feature Engineering

Selain proses cleaning, dilakukan feature engineering untuk menghasilkan kolom-kolom turunan yang lebih informatif:

Kolom Baru	Dasar Pembuatan	Kegunaan
experience_level	Mapping dari kolom Experience (integer)	Label deskriptif level karir (Entry/Mid/Senior/dll)
education_rank	Ordinal encoding dari kolom Education	Analisis korelasi numerik pendidikan-salary
Education_Label	Human-readable mapping dari Education enum	Tampilan dashboard
Job_Type_Label	Human-readable mapping dari Job_Type enum	Tampilan dashboard
Work_Arr_Label	Human-readable mapping dari Work Arrangement enum	Tampilan dashboard
skill_count	Panjang daftar skill per posting	Proxy kompleksitas posisi
salary_range_width	Max salary - Min salary (IDR dan USD)	Proxy fleksibilitas negosiasi gaji
has_salary	Flag boolean: posting dengan/tanpa info salary	Filter untuk analisis salary

Tabel 4.4 — Kolom Hasil Feature Engineering

4.4 Hasil Akhir Cleaning

Setelah seluruh proses cleaning selesai, dataset final memiliki karakteristik sebagai berikut:

Metrik	Nilai
Total baris dataset final	48030 Baris
Total kolom dataset final	37 Kolom
Baris dengan informasi salary valid	40958 (85.3%)
Baris tanpa salary (has_salary=False)	7072 (14.7%)
Total unique skill setelah normalisasi	8218 Skill
Total unique industri	139 Industri
Total unique job_category_parent	65 Kategori

Tabel 4.5 — Statistik Dataset Final Setelah Cleaning

```

RangeIndex: 48030 entries, 0 to 48029
Data columns (total 37 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Job_Link                              48030 non-null  object
1   Title                                48030 non-null  object
2   Industry                             48030 non-null  object
3   Job_Category_parent                  48030 non-null  object
4   Job_Category                         48030 non-null  object
5   Salary_Mode                          40958 non-null  object
6   Min_Salary                          40958 non-null  float64
7   Max_Salary                          40958 non-null  float64
8   Skills                              48030 non-null  object
9   Job_Type                             48030 non-null  object
10  Work Arrangement                     48030 non-null  object
11  Education                           48030 non-null  object
12  Experience                           48030 non-null  int64
13  skills_list                          48030 non-null  object
14  multiplier                           40958 non-null  float64
15  salary_min_monthly                   48030 non-null  float64
16  salary_max_monthly                   48030 non-null  float64
17  salary_min_usd                       40958 non-null  float64
18  salary_max_usd                       40958 non-null  float64
19  has_salary                           48030 non-null  bool
...
35  Work_Arr_Label                       48030 non-null  object
36  skill_count                          48030 non-null  int64
dtypes: bool(1), category(2), float64(16), int64(3), object(15)

```

Gambar 4.2 — Statistik Dataset Setelah Proses Cleaning


BAB V — EXPLORATORY DATA ANALYSIS (EDA)

5.1 Pendekatan Analisis

Exploratory Data Analysis dilakukan untuk menjawab tujuh research questions utama yang telah ditetapkan di awal proyek. Setiap pertanyaan dijawab menggunakan kombinasi statistik deskriptif, visualisasi data, dan analisis komparatif. Hasil EDA ini menjadi fondasi insight yang disajikan pada dashboard Streamlit dan menjadi referensi pengembangan fitur Karisma AI.

5.2 Distribusi Industri dan Ekosistem Pasar Kerja

Analisis pertama dilakukan untuk memahami distribusi posting lowongan berdasarkan industri, sehingga dapat diketahui sektor mana yang paling aktif merekrut tenaga kerja pada periode pengumpulan data.




Gambar 5.1 — Distribusi Posting Lowongan Berdasarkan Industri (Top 10)

Industry Retail Mendominasi dengan 4528 lowongan (9.4%), diikuti Education Management 4231 lowongan (8.8%) dan Food & Beverages 3349 lowongan (7.0%). Ketiga Industri ini mewakili 25.2 % dari seluruh lowongan.

5.3 Analisis Distribusi Job Type dan Work Arrangement

Analisis ini bertujuan untuk memahami preferensi model kerja yang ditawarkan oleh perusahaan di Indonesia, khususnya terkait perkembangan tren remote working pasca pandemi.



Gambar 5.2 — Distribusi Job Type dan Work Arrangement


Distribusi Tipe Pekerjaan diisi dengan mayoritas lowongan yang bersifat Full Time sebanyak 32405 lowongan (67.5%), kemudian Kontrak sebanyak 7829 lowongan (16.3%), diikuti Magang sebanyak 3090 lowongan (6.4%), selanjutnya Part Time sebanyak 2535 lowongan (5.3%) dan terakhir Project Based sebanyak 2171 lowongan (4.5%).

Distribusi Work Arrangement diisi dengan mayoritas lowongan yang berkerja dengan Onsite sebanyak 41396 (86.2%), kemudian Hybrid sebanyak 5249 lowongan (10.9%) dan terakhir Remote sebanyak 1385 (2.9%).

5.4 Analisis Skill Paling Diminati dan Skill Premium


Analisis skill merupakan bagian paling krusial dari penelitian ini, karena hasil analisis skill menjadi inti dari fitur skill gap dan career recommendation di Karisma AI. Terdapat dua dimensi analisis skill yang dilakukan:

- Skill frequency: skill apa yang paling banyak diminta oleh perusahaan secara keseluruhan.
- Skill premium: skill apa yang berkorelasi dengan kompensasi yang lebih tinggi (salary_avg_usd di atas rata-rata).



Gambar 5.3 — Top Skill yang Paling Banyak Diminta oleh Industri

Communication, teamwork, dan customer service secara konsisten berada di posisi tiga teratas sebagai kompetensi yang paling banyak dicari, dengan *communication* mendominasi di angka 11477 kemunculan. Hal ini mengindikasikan bahwa keahlian interpersonal dan komunikasi tetap menjadi fondasi utama yang paling krusial di pasar kerja. Sementara itu, dari sisi pemenuhan kualifikasi, mayoritas pemberi kerja cenderung menetapkan persyaratan yang cukup spesifik dan terfokus, di mana sebagian besar lowongan secara dominan hanya mensyaratkan 3 hingga 5 keahlian saja untuk satu posisi jabatan.




Gambar 5.4 — Skill dengan Korelasi Tertinggi terhadap Tingkat Kompensasi (Skill Premium)

Keahlian di bidang infrastruktur digital seperti Google Cloud Platform (GCP) dan Cloud Computing mendominasi sebagai keterampilan dengan kompensasi tertinggi, masing-masing mencatatkan median gaji sebesar 10,8 Jt dan 10,5 Jt per bulan. Selain dominasi sektor teknologi tingkat lanjut—seperti Microservices Architecture, DevOps, dan Cybersecurity—keahlian spesifik seperti Chinese-Indonesian Translation juga terbukti menjadi premium skill yang sangat dihargai di pasar. Secara keseluruhan, seluruh 20 keahlian teratas ini menghasilkan pendapatan di atas 9 Jt per bulan, melesat hingga lebih dari dua kali lipat dibandingkan median pasar yang hanya berada di angka 3,9 Jt per bulan.

5.5 Analisis Korelasi Pengalaman dan Kompensasi

Analisis ini menguji hipotesis bahwa terdapat hubungan positif antara tingkat pengalaman yang dibutuhkan dengan kompensasi yang ditawarkan, serta mengidentifikasi apakah pola tersebut konsisten di seluruh kategori pekerjaan.




Gambar 5.5 — Distribusi Rata-rata Gaji berdasarkan Experience Level

Terdapat tren peningkatan kompensasi yang konsisten dan signifikan seiring meningkatnya jenjang pengalaman kerja, di mana posisi Entry Level (0 thn) dimulai dengan median gaji sekitar 3 Juta Rp/bulan dan melonjak hingga mencapai median sekitar 12,5 Juta Rp/bulan pada level Senior (>6 thn). Melalui visualisasi *heatmap*, terlihat bahwa eskalasi pendapatan ini sangat dipengaruhi oleh kluster pekerjaan; sektor Computer & Software sudah menunjukkan kompensasi yang kompetitif sejak level *Mid Level* (22,8 Juta Rp), sementara sektor lain seperti Accounting dan Nutrition & Rehabilitation mencatatkan lonjakan premium yang sangat masif di tingkat *Senior*, masing-masing hingga menyentuh angka 22,5 Juta dan 30 Juta Rp/bulan.

5.6 Analisis Distribusi Salary dan Salary Tier

Analisis distribusi salary bertujuan untuk memahami struktur kompensasi di pasar kerja Indonesia secara keseluruhan, serta mengidentifikasi segmentasi berdasarkan tier salary.



Gambar 5.6 — Distribusi Rata Rata Gaji dan Salary Tier


Salary Tier	Rentang (RP/bulan)	Jumlah Posting	Persentase (%)
Low	< Rp 2 Juta	7500	15.6%
Low-Mid	Rp 2 – 5 Juta	20635	43.0%
Mid	Rp 5 – 10 Juta	10736	22.4%
Mid-High	Rp 10 – 20 Juta	1830	3.8%
High	> Rp 20 Juta	257	0.5%
No Salary	N/A	7072	14.7%

Tabel 5.1 — Distribusi Posting Lowongan berdasarkan Salary Tier

Pasar kerja saat ini didominasi oleh penawaran kompensasi pada tingkat menengah ke bawah, di mana rentang Rp 2–5 Jt menjadi kelompok terbesar dengan porsi mencapai 43,0% (20.635 posting). Nilai rata-rata hitung (*mean*) gaji tercatat sebesar Rp 4,6 Jt/bulan, sedikit lebih tinggi dibandingkan nilai tengah (*median*) pasar yang berada di angka Rp 3,9 Jt/bulan akibat adanya pengaruh dari penawaran gaji tinggi (> Rp 20 Jt) yang bersifat eksklusif karena hanya mencakup 0,5% dari total lowongan. Di sisi lain, fenomena transparansi upah masih menjadi tantangan tersendiri dengan adanya 14,7% lowongan yang dipublikasikan tanpa mencantumkan informasi gaji sama sekali.

5.7 Analisis Kategori Pekerjaan dengan Kompensasi Tertinggi

Analisis ini mengidentifikasi fungsi pekerjaan (*job_category_parent*) yang menawarkan kompensasi rata-rata tertinggi, sebagai dasar rekomendasi jalur karir dengan return on investment terbaik bagi mahasiswa.




Gambar 5.7 — Top Job Category berdasarkan Rata-rata Gaji

Kategori pekerjaan dengan kompensasi tertinggi didominasi kuat oleh peran spesialisasi tingkat lanjut, yang dipimpin oleh Senior Technical Position dengan median gaji mencapai 12,0 Juta Rp/bulan, diikuti oleh bidang Translation di angka 9,5 Juta Rp/bulan. Kelompok teratas ini didominasi oleh fungsi-fungsi teknis dan manajemen strategis seperti *Backend Development*, *Product Management*, serta *Project Management*. Menariknya, terdapat ketimpangan (*skewness*) yang cukup besar pada kategori Leadership & Senior Management dan Sales Management, di mana nilai rata-rata (*mean*) jauh melampaui nilai mediannya—mengindikasikan adanya segelintir posisi elit di kluster tersebut yang menawarkan kompensasi sangat tinggi (pencilan atas) dibanding mayoritas posisi lainnya.

5.8 Analisis Distribusi Pendidikan dengan Salary

Analisis tambahan dilakukan untuk memahami persyaratan pendidikan minimum yang paling umum di pasar kerja, serta distribusi rata rata gaji berdasarkan Pendidikan minimum nya.



Gambar 5.8 — Distribusi Persyaratan Pendidikan dengan rata rata gaji

Secara umum, terdapat korelasi positif yang linier antara tingkat pendidikan minimum dengan kompensasi yang ditawarkan, di mana median gaji terkecil dimulai dari tingkat SMP sebesar 2,5 Jt dan memuncak pada tingkat S3 mencapai 5,8 Jt per bulan. Penawaran lowongan kerja di pasar sangat terkonsentrasi pada lulusan S1 (16.187 lowongan), Diploma (12.030 lowongan), dan SMA/SMK (9.802 lowongan). Menariknya, tingkat pendidikan S1, Profesional, dan S2 berada pada titik ekuilibrium kompensasi yang sama dengan median gaji sebesar 5,0 Jt per bulan, menunjukkan bahwa pada kelompok pendidikan tinggi tersebut, faktor kompetensi praktis atau spesialisasi industri kemungkinan lebih menentukan nilai tawar upah dibanding sekadar gelar akademik formal.

BAB VI — FILE OUTPUT DAN SPESIFIKASI DATA

6.1 Strategi Output Multi-Format

Hasil dari proses analisis dan cleaning menghasilkan tiga file output dengan tujuan dan spesifikasi yang berbeda, dirancang untuk memenuhi kebutuhan tiga konsumen data yang berbeda: tim AI Engineer, tim Full-Stack Developer, dan database production Supabase.

File Output	Granularitas	Konsumen Data	Tujuan Utama
glints_nlp_ready.csv	1 baris = 1 lowongan	AI Engineer	Input training & inferensi model NLP
glints_v2_cleaned.csv	1 baris = 1 lowongan	Data Science	Dashboard Streamlit & visualisasi
glints_category_output.csv	1 baris = 1 kategori	Full Stack	Seeding tabel Supabase production

Tabel 6.1 — Ringkasan Tiga File Output Pipeline Data Science

6.2 glints_nlp_ready.csv — File untuk Model NLP

File ini dirancang sebagai input langsung untuk proses training model NLP skill extractor dan career classifier yang dikerjakan oleh tim AI Engineer. Seluruh kolom telah dikodekan secara numerik atau dalam format yang dapat langsung diproses oleh framework TensorFlow.

Karakteristik utama file ini adalah:

- Skills disimpan dalam format `skills_list` (Python list canonical names) bukan string mentah.
- Salary telah dinormalisasi ke rentang `[0, 1]` dalam kolom `salary_normalized`.
- Semua variabel kategorikal memiliki padanan encoded (`salary_tier_encoded`, `education_rank`).
- Flag `has_salary` memudahkan filtering untuk analisis yang membutuhkan data salary valid.

Total kolom pada file ini: 20 Kolom. Total baris: 48030 Baris.

6.3 glints_v2_cleaned.csv — File untuk Dashboard Streamlit

File ini adalah versi dataset yang paling lengkap dan human-readable, dirancang untuk dikonsumsi oleh Streamlit dashboard dan analisis visualisasi. Seluruh nilai kategorikal memiliki label yang mudah dipahami (Education_Label, Job_Type_Label, Work_Arr_Label), dan kolom salary tersedia dalam berbagai format (IDR Juta, USD, normalized).

Total kolom pada file ini: 30 Kolom. Total baris: 48030 Baris.

6.4 glints_category_output.csv — File untuk Database Seeding

File ini merupakan hasil agregasi dari dataset utama yang di-groupby berdasarkan kolom `job_category_parent`. Setiap baris merepresentasikan satu kategori pekerjaan unik, dengan kolom `min_avg_salary` dan `max_avg_salary` yang merupakan rata-rata dari `salary_min_usd` dan `salary_max_usd` seluruh posting dalam kategori tersebut (hanya posting dengan `has_salary=True`).

File ini secara langsung di-consume oleh script `seeding_skills_database.py` untuk mengisi tabel `Job_listings`, `Skills`, dan `Job_Skills` di Supabase.

Metrik	Nilai
Total unique <code>job_category_parent</code> (baris)	65 Baris
Total unique skill di seluruh kategori	8218 Skills
Kategori dengan rata-rata gaji tertinggi	17.5 Juta/bulan
Kategori dengan rata-rata gaji terendah	2.5 Juta/bulan


Tabel 6.2 — Statistik `glints_category_output.csv`

BAB VII — STREAMLIT EDA DASHBOARD

7.1 Gambaran Umum Dashboard

Streamlit EDA Dashboard dikembangkan sebagai antarmuka publik yang menyajikan insight hasil analisis data pasar kerja Indonesia kepada pengguna umum. Dashboard ini berfungsi sebagai komponen transparansi data dari proyek Karisma AI, memungkinkan siapapun untuk mengeksplorasi tren skill dan kompensasi industri tanpa perlu menjalankan notebook secara lokal.

Dashboard telah berhasil di-deploy ke Streamlit Cloud dan dapat diakses secara publik pada URL: [Job Market Dashboard · Streamlit](#)



Gambar 7.1 — Tampilan Halaman Utama Streamlit EDA Dashboard


7.2 Struktur dan Fitur Dashboard

Dashboard terdiri dari beberapa section yang mencakup visualisasi komprehensif dari hasil EDA. Berikut adalah struktur dan fitur yang tersedia:


Section / Halaman	Visualisasi yang Tersedia	Isi Halaman
Overview	Dashboard Kondisi Pasar, Distribusi lowongan kerja, dan Insight Analisis	KPI utama, ringkasan dataset, dan 7 insight
Job Market Analysis	Bar Chart Top Industri dan Job Cluster, Bar Chart Top Job Category, Pie Chart Tipe &	Distribusi industri, job cluster, tipe & arrangement pekerjaan

Section / Halaman	Visualisasi yang Tersedia	Isi Halaman
	Arrangement Pekerjaan, Bar Chart Arrangement Pekerjaan per Job Cluster	
Salary Analysis	Histogram Rata Rata Gaji dan Salary Tier, Bar Chart Rata rata gaji Top Industri dan Cluster, Bar Chart Salary Top Job Category dan Box Plot Salary dengan Tipe pekerjaan, Bubble Chart Skill dengan Salary, Heatmap Salary dengan Industri x Experience, Bar Chart Salary dengan minimum Pendidikan	Distribusi salary, perbandingan per industri, experience, Pendidikan pasar kerja Indonesia
Skill Analysis	Bar Chart Top Skill, Bar Chart Skill dengan Top Salary, Bar Chart Skill Versatile,	Top skills, skill premium, dan skill paling versatile
Job Explorer	Filter Pencarian lowongan dengan Slider Rentang gaji, Tabel Hasil Filter	Filter & cari lowongan spesifik secara interaktif


Tabel 7.1 — Struktur Section dan Fitur Streamlit Dashboard




Gambar 7.2 — Section Overview Pada Dashboard




Gambar 7.3 — Section Job Market Analysis pada Dashboard



Gambar 7.4 — Section Salary Analysis pada Dashboard



Gambar 7.5 — Section Skill Analysis pada Dashboard



Gambar 7.6 — Section Job Analysis pada Dashboard

7.3 Teknologi Implementasi Dashboard

Dashboard dibangun menggunakan Streamlit versi 1.35.0 dengan library visualisasi Plotly untuk grafik interaktif. Sumber data dashboard adalah file `glints_v2_cleaned.csv` yang dimuat ke dalam DataFrame Pandas saat inisialisasi aplikasi. Beberapa optimasi performa telah diterapkan:

- Penggunaan dekorator `@st.cache_data` untuk meng-cache pemuatan dataset agar tidak dibaca ulang setiap interaksi pengguna.
- Lazy loading pada section yang memiliki komputasi berat.

Deployment dilakukan ke Streamlit Community Cloud menggunakan repository GitHub yang terhubung langsung, sehingga setiap push ke branch utama akan memicu proses deployment otomatis.

BAB VIII — DATABASE SEEDING DAN INTEGRASI PRODUCTION

8.1 Arsitektur Database

Data yang telah diproses oleh pipeline Data Science diintegrasikan ke dalam database production Supabase (PostgreSQL) yang menjadi sumber data utama bagi backend aplikasi Karisma AI. Integrasi ini dilakukan melalui script `seeding_skills_database.py` yang membaca `glints_category_output.csv` dan mengisi tiga tabel secara transaksional.

Skema database yang digunakan adalah sebagai berikut:

Tabel	Kolom Utama	Sumber Data	Deskripsi
Job_listings	id (UUID), Job, Min_Salary, Max_Salary, created_at	job_category_parent, min_avg_salary, max_avg_salary	1 baris per kategori pekerjaan unik
Skills	id (UUID), Skill_name	skills_list (seluruh unique skill)	1 baris per skill unik di seluruh dataset
Job_Skills	id (UUID), Job_listing_id (FK), Skills_id (FK)	Relasi dari Job_listings dan Skills	Tabel many-to-many penghubung job dan skill

Tabel 8.1 — Skema Database Supabase Production

8.2 Proses Seeding

Script seeding berjalan dalam satu transaksi database tunggal yang mencakup tiga operasi INSERT secara berurutan. Pendekatan transaksional ini memastikan konsistensi data: jika salah satu INSERT gagal, seluruh transaksi akan di-rollback sehingga tidak ada data parsial yang tersimpan.

Proses seeding dilakukan dalam urutan berikut untuk menjaga integritas referensial:

1. Insert ke tabel Job_listings (data job_category_parent + salary rata-rata).
2. Insert ke tabel Skills (semua unique skill dari seluruh dataset).
3. Insert ke tabel Job_Skills (relasi many-to-many job dan skill, dengan deduplication).

Seluruh INSERT menggunakan klausa ON CONFLICT (id) DO NOTHING untuk memastikan script dapat dijalankan ulang (idempotent) tanpa menyebabkan duplikasi data.

8.3 Hasil Seeding Production

Proses seeding ke database Supabase production berhasil dilaksanakan dengan hasil sebagai berikut:

Tabel	Jumlah Records Berhasil Di-insert	Keterangan
Job_listings	65 Records	Unique job_category_parent
Skills	8218 Records	Unique canonical skills
Job_Skills	18041 Records	Unique relasi job-skill
TOTAL	26324 Records	Seluruh records di database

Tabel 8.2 — Hasil Seeding Database Production

```
PS C:\code\Scrapping_glints> python -u "c:\code\Scrapping_glints\Final_DS\seeding_skills_database.py"
Membaca glints_category_output.csv ...
65 baris | 65 unique job_category_parent

Menyiapkan Job_listings ...
→ 65 job records

Menyiapkan Skills (tanpa batasan) ...
→ 8,218 unique skills

Menyiapkan Job_Skills ...
→ 18,041 unique relasi Job_Skills

Menghubungkan ke Supabase ...
```

Gambar 8.1 — Output Terminal Proses Database Seeding

	public.Skills	public.Job_Skills	public.Job_listings	+
Q	Filter by id, Skill_name or ask AI			
☐	id uuid	Skill_name varchar		
☐	0006d548-24e3-40a4-a379-a587deda79c	elevator		
☐	00095446-2acc-477a-9351-ab4c3b09c95	ultrasonic welding		
☐	00098c51-824e-44a6-976c-54fb33bdb5b	microsoft access		
☐	000f3b49-7069-4b93-9941-6fb7790a1a7c	bizagi		
☐	0013f61a-bda8-462f-a23b-bfed39fa8f45	sales force mapping		
☐	001944ab-f50d-4967-ad6a-cbab3d913e17	screenwriting		
☐	001c2fd5-9ec4-41bb-89c6-01f9bffc299	assembly process		
☐	00372d57-2c10-49ba-9171-59f4a89a3fcd	communication & persuasion		
☐	003f9182-3880-4313-8d5d-00d5cbf6d8de	data pipeline		
☐	0041faa3-2dd1-4fdf-ab6b-bfe4f2019d02	telecommunication sales		
☐	00478e9f-3bb7-4e68-ba89-363a5916ccdf	medical translation		
☐	0050f0d5-5536-4a84-92bc-17c9db9b979	organic farming		

Gambar 8.2 — Data di Supabase Table Editor

BAB IX — TEMUAN UTAMA DAN IMPLIKASI

9.1 Ringkasan Temuan Utama

Berdasarkan seluruh proses analisis yang telah dilakukan, berikut adalah temuan-temuan utama dari eksplorasi data pasar kerja Indonesia melalui platform Glints:

Dimensi Analisis	Temuan Utama
Industri Paling Aktif	- Retail: 4,528 lowongan (9.4%) - Education Management: 4,231 lowongan (8.8%) - Food & Beverages: 3,349 lowongan (7.0%)
Skill Paling Diminati	- communication: 13,517 lowongan (28.1%) - teamwork: 9,799 lowongan (20.4%) - customer service: 8,417 lowongan (17.5%) - sales and marketing: 6,201 lowongan (12.9%) - microsoft office: 5,654 lowongan (11.8%)
Skill Premium	- Google Cloud Platform: median Rp 10.8 Jt/bulan (n=45) - Cloud Computing: median Rp 10.5 Jt/bulan (n=31) - Microservices Architecture: median Rp 10.0 Jt/bulan (n=59)
Rata-rata Gaji	Median : Rp 3.9 Jt/bulan Mean : Rp 4.6 Jt/bulan
Work Arrangement	Onsite: 41396 lowongan (86.2%) Hybrid: 5249 lowongan (10.9%) Remote: 1385 lowongan (2.9%)
Posting Tanpa Salary	7072 lowongan tanpa Salary (14.7%)
Pendidikan Dominan	Sarjana S1: 16187 lowongan (39.5%)
Kategori Bergaji Tertinggi	- Senior Technical Position: median Rp 12.0 Jt/bulan - Translation: median Rp 9.5 Jt/bulan - Backend Development: median Rp 7.5 Jt/bulan

Tabel 9.1 — Ringkasan Temuan Utama EDA

9.2 Implikasi untuk Pengembangan Karisma AI

Temuan-temuan dari EDA memiliki implikasi langsung terhadap pengembangan fitur Karisma AI:

9.2.1 Implikasi untuk Model NLP

- Ketimpangan distribusi data antar kategori pekerjaan (beberapa kategori memiliki jauh lebih banyak posting) mengharuskan penerapan teknik class balancing seperti Focal Loss pada model career classifier, yang telah diantisipasi oleh tim AI Engineer.
- Hasil normalisasi skill menunjukkan bahwa SKILL_CANONICAL dict berhasil mereduksi noise secara signifikan, sehingga representasi skill yang lebih bersih dapat meningkatkan akurasi model.

9.2.2 Implikasi untuk Fitur Skill Gap

- Tersedianya data min_avg_salary dan max_avg_salary per kategori pekerjaan di database memungkinkan fitur skill gap untuk tidak hanya menampilkan kekurangan skill, tetapi juga proyeksi potensi peningkatan kompensasi jika skill gap berhasil ditutup.
- Skill-skill premium yang teridentifikasi dapat diprioritaskan dalam rekomendasi roadmap pengembangan diri, memberikan nilai strategis yang lebih tinggi bagi pengguna.

9.2.3 Implikasi untuk User Experience

- Tingginya persentase posting tanpa informasi salary (14.7%) perlu dikomunikasikan kepada pengguna Karisma AI agar ekspektasi terhadap akurasi prediksi salary dapat dikelola dengan tepat.

9.3 Keterbatasan Penelitian

Beberapa keterbatasan yang perlu diakui dalam penelitian ini:

- Data bersumber dari satu platform (Glints) sehingga belum merepresentasikan keseluruhan pasar kerja Indonesia. Platform lain seperti LinkedIn, Kalibrr, atau Indeed mungkin memiliki distribusi skill dan salary yang berbeda.
- Data merupakan snapshot pada periode Mei 2026, sehingga tidak mencerminkan perubahan kebutuhan skill yang terjadi setelahnya.
- Informasi salary yang tercantum merupakan informasi yang diinput secara mandiri oleh perusahaan dan belum terverifikasi akurasinya. Terdapat

kemungkinan under-reporting (perusahaan tidak mencantumkan salary) yang dapat membiaskan analisis kompensasi.

BAB X — KESIMPULAN DAN REKOMENDASI

10.1 Kesimpulan

Laporan ini telah mendokumentasikan secara komprehensif seluruh pipeline Data Science yang dibangun dalam proyek Karisma AI, dari pengumpulan data melalui web scraping hingga penyediaan data terstruktur untuk kebutuhan production. Beberapa kesimpulan utama yang dapat ditarik adalah:

1. Pipeline data yang dibangun berhasil mengumpulkan lebih dari 60.000 data lowongan kerja dari platform Glints Indonesia melalui kombinasi 1.008 filter query, menghasilkan dataset yang representatif dari berbagai industri, kategori pekerjaan, dan level pengalaman.
2. Proses cleaning dan normalisasi yang diterapkan secara signifikan meningkatkan kualitas data, terutama dalam hal normalisasi salary ke satu basis (IDR/bulan dan USD/bulan) dan normalisasi nama skill melalui SKILL_CANONICAL mapping, sehingga menghasilkan dataset yang konsisten dan dapat diandalkan untuk analisis.
3. Hasil EDA mengungkap pola-pola penting di pasar kerja Indonesia: pasar kerja saat ini didominasi oleh model kerja Onsite sebesar 86,2% dengan sektor Retail dan Education Management sebagai industri paling aktif mencari tenaga kerja. Sejalan dengan dominasi tersebut, keahlian interpersonal seperti *communication* (28,1%) dan *teamwork* menjadi kompetensi yang paling masif diminta untuk kualifikasi pendidikan dominan Sarjana S1 (39,5%). Di sisi lain, meskipun rata-rata median gaji pasar berada di angka Rp 3,9 Jt/bulan, ceruk pasar teknologi tingkat lanjut menawarkan kompensasi premium yang jauh lebih tinggi melalui peran spesifik seperti Senior Technical Position dengan median mencapai Rp 12,0 Jt/bulan.
4. Tiga file output yang dihasilkan (*glints_nlp_ready.csv*, *glints_v2_cleaned.csv*, *glints_category_output.csv*) telah berhasil memenuhi kebutuhan tiga konsumen data yang berbeda: model AI, dashboard Streamlit, dan database production Supabase.
5. Streamlit EDA Dashboard yang telah di-deploy memberikan aksesibilitas publik terhadap insight data pasar kerja Indonesia tanpa memerlukan keahlian teknis dari pengguna akhir.

10.2 Rekomendasi Pengembangan ke Depan

Berdasarkan pengalaman dan temuan selama pengerjaan proyek ini, beberapa rekomendasi untuk pengembangan ke depan adalah:

- Ekspansi sumber data: mengintegrasikan data dari platform lain (LinkedIn, Kalibrr, JobStreet) untuk mendapatkan gambaran pasar kerja yang lebih komprehensif dan mengurangi bias sumber tunggal.
- Scraping berkala dan pembaruan model: mengatur jadwal scraping periodik (misalnya mingguan atau bulanan) sehingga model dan dashboard dapat mencerminkan kondisi pasar kerja terkini.
- Peningkatan normalisasi skill: memperluas SKILL_CANONICAL dict menggunakan teknik NLP seperti word embedding atau fuzzy matching untuk menangkap variasi penulisan yang lebih kompleks.
- Analisis temporal: dengan data yang terus diperbarui, dapat dilakukan analisis tren skill dari waktu ke waktu untuk mengidentifikasi skill yang sedang naik atau turun permintaannya.